


A diagram of a human brain from a top-down perspective, illustrating neural pathways and emotional states. The brain is divided into various regions, each labeled with a French word representing an emotion or state. The labels include: Positif (Positive), Neutre (Neutral), Joie (Joy), Tristesse (Sadness), Négatif (Negative), and Corbis (Cortex). The pathways are represented by colored dots (blue, green, orange, red) connected by lines, indicating the flow of information between different parts of the brain. The overall theme is the connection between neural activity and emotional experience.

Naima OUBENALI

NEXA
Digital School

Qu'est-ce que l'Analyse de sentiments ?



- **Définition** : Utilisation du traitement automatique du langage naturel (TALN) pour identifier et extraire des informations subjectives.
- **Objectif** : Comprendre les émotions, attitudes et opinions exprimées dans un texte.

Concepts Clés en Analyse de sentiments

Polarité




Classification du sentiment comme positif, négatif ou neutre.

Subjectivité vs. Objectivité



Distinction entre les déclarations factuelles et les opinions personnelles.


Analyse basée sur l'aspect (ABSA)





Identification des sentiments liés à des caractéristiques spécifiques d'un produit ou service.

Méthodes d'Analyse de sentiments

Approche basée sur des lexiques



Approche basée sur l'apprentissage automatique



Applications de l'Analyse de sentiments



Surveillance des réseaux sociaux

Suivi de la perception de la marque et de la réputation en ligne.

Analyse des avis clients



Compréhension des commentaires pour améliorer les produits et services.



Analyse financière

Prédiction des tendances du marché à partir des actualités et rapports.



Analyse politique


Évaluation de l'opinion publique sur les candidats et les politiques.

Étapes de Prétraitement de Texte pour l'Analyse de Sentiments


Guide avec Bouts de Code en Python

Présenté par **Naima OUBENALI**

Introduction



Etapes de prétraitement standards



1. Normalisation (Nettoyage)

Objectif : Uniformiser le texte.

Actions : Conversion en minuscules, suppression de la ponctuation, des nombres et des caractères spéciaux.

```
import re

text = "C'est génial! Note: 5/5."

# Minuscules
text = text.lower()

# Suppression ponctuation et nombres
text = re.sub(r'^a-z\s]', '', text)

print(text)

# c'est génial note
```

1. Normalisation / Cleaning

Normalization is pre-processing the text data so it is homogenous

- Case folding: Reducing all letters to lowercase
e.g., *Doctor* → *doctor*, *PatiEnT* → *patient*
- Punctuation: Removing unnecessary punctuation
e.g., *I.M.C* → *IMC*, *l'ensemble* → *I ensemble*
- Numbers: Removing numbers when non relevant to the analysis
- Accents, special characters, special words:
e.g., *intérêt* → *interet*, α, ϵ, ξ → $\emptyset$, 😊 , 😁 → *:happy*:



`.lower()`

DEMO

```
import re
```

```
text = """
Cher confrère, madame a été admise pour une hémorragie cérébrale....
Elle est actuellement aux soins intensifs, et a besoin d'une opération en urgence!!!
() Ce courrier est à transmettre au chef du service Neurochirurgie. Mail du médecin traitant: medecintraitant@gmail.com
$ù*$ numéro de téléphone: 04395835035
"""
```

```
# Replace accented characters with unaccented characters
text = text.replace('é', 'e').replace('à', 'a').replace('è', 'e').replace('ù', 'u')
text
```

```
"\nCher confrere, madame a ete admise pour une hemorragie cerebrale.... \nElle est actuellement aux soins intensifs, et a besoin d'une operation en ur
gence!!! \n() Ce courrier est a transmettre au chef du service Neurochirurgie. Mail du medecin traitant: medecintraitant@gmail.com \n$u*$ numero de t
elephone: 04395835035\n"
```

```
# Remove unwanted characters and white spaces
text = re.sub('[^A-Za-z0-9\s]+', '', text)
text
```

```
'\nCher confrere madame a ete admise pour une hemorragie cerebrale \nElle est actuellement aux soins intensifs et a besoin dune operation en urgence
\n Ce courrier est a transmettre au chef du service Neurochirurgie Mail du medecin traitant medecintraitantgmailcom \nuu numero de telephone 043958350
35\n'
```

```
# Convert all characters to lowercase
text = text.lower()
```

```
# Print the cleaned text
print(text)
```

```
cher confrere madame a ete admise pour une hemorragie cerebrale
elle est actuellement aux soins intensifs et a besoin dune operation en urgence
ce courrier est a transmettre au chef du service neurochirurgie mail du medecin traitant medecintraitantgmailcom
uu numero de telephone 04395835035
```

Exercice

Créer une fonction de nettoyage du texte qui prend en compte l'ensemble des étapes de normalisation possibles :

- Transformer en minuscule
- Remplacer les lettres avec accent
- Enlever les caractères spéciaux
- Enlever certains signes de ponctuation
- Enlever les espaces multiples
- Enlever les chiffres
- Enlever les retours à la ligne \n

2. Tokenisation

Objectif : Diviser le texte en unités individuelles (**tokens**), généralement des mots.

```
import nltk
from nltk.tokenize import word_tokenize

# Nécessite le téléchargement préalable:
nltk.download('punkt')
text = "L'analyse de sentiments est utile."
tokens = word_tokenize(text,
language='french')
print(tokens)

# ['L'', 'analyse', 'de', 'sentiments',
'est', 'utile', '.']
```

2. Tokenisation: méthodes

- **Word tokenization:** ['traumatisme', 'cranien', 'au', 'niveau', 'du', 'vertex']
→ **Issues:**
 - Out of Vocabulary words
 - Size of Vocabulary
- **Character tokenization:** [['t', 'r', 'a', 'u', 'm', 'a', 't', 'i', 's', 'm', 'e'], ['c', 'r', 'a', 'n', 'i', 'e', 'n']]
→ **Issues:**
 - The size of the input and output sentences
- **Subword tokenization** (n-grams)
 - (2-grams): ['tr', 'ra', 'au', 'um', 'ma', 'at', 'ti', 'is', 'sm', 'me']
 - (3-grams): ['tra', 'rau', 'uma', 'ati', 'ism', 'me']

Tokenisation

BERT tokenizer

```
Text = ['Le', '07/08', ':', 'chute', 'dans', 'les', 'escaliers', 'en', 'lien', 'avec', 'une', 'maladresse', ':',  
'Traumatisme', 'crânien', 'au', 'niveau', 'du', 'vertex', ',', 'sans', 'perte', 'de', 'connaissance', '.']
```

```
Tokenized_text = ['Le', '07/08', ':', 'chute', 'dans', 'les', 'esca', '##liers', 'en', 'lien', 'avec',  
'une', 'mal', '#adre', '##sse', ':', 'Trau', '##mat', '##isme', 'cran', '##ien', 'au', 'niveau', 'du',  
'vertex', ',', 'sans', 'perte', 'de', 'conn', '##aiss', '##ance', '.']
```

Tokenization: Outils



spaCy



gensim

K Keras

`.split()`

Sentencizing

Sentencizing is the process of splitting the text into sentences, based on line breaks, punctuation or other patterns.

e.g.,

Text = ['Le 07/08: chute dans les escaliers en lien avec une maladresse. Traumatisme crânien au niveau du vertex, sans perte de connaissance.']

Sentence1 = { 'Le', '07/08', ':', 'chute', 'dans', 'les', 'escaliers', 'en', 'lien', 'avec', 'une', 'maladresse', '.' }

Sentence2 = { 'Traumatisme', 'cranien', 'au', 'niveau', 'du', 'vertex', ',', 'sans', 'perte', 'de', 'connaissance', '.' }

DEMO

```
[1]: import nltk

[7]: nltk.download('punkt')

[nltk_data] Downloading package punkt to
[nltk_data] C:\Users\naima\AppData\Roaming\nltk_data...
[nltk_data] Unzipping tokenizers\punkt.zip.

[7]: True

[9]: text = """
    Cher confrère,
    madame a été admise pour une hémorragie cérébrale. Elle est actuellement aux soins intensifs, et a besoin d'une opération en urgence.
    Ce courrier est à transmettre au chef du service Neurochirurgie.
    """

•[10]: # Sentencizing the text

    sentences = nltk.tokenize.sent_tokenize(text)

[11]: sentences

[11]: ['\nCher confrère,\nmadame a été admise pour une hémorragie cérébrale.',
      "Elle est actuellement aux soins intensifs, et a besoin d'une opération en urgence.",
      'Ce courrier est à transmettre au chef du service Neurochirurgie.']

•[13]: # Tokenizing each sentence into words

    for sentence in sentences:
        mots = nltk.word_tokenize(sentence)
        print(mots)

['Cher', 'confrère', ',', 'madame', 'a', 'été', 'admise', 'pour', 'une', 'hémorragie', 'cérébrale', '.']
['Elle', 'est', 'actuellement', 'aux', 'soins', 'intensifs', ',', 'et', 'a', 'besoin', 'd\'une', 'opération', 'en', 'urgence', '.']
['Ce', 'courrier', 'est', 'à', 'transmettre', 'au', 'chef', 'du', 'service', 'Neurochirurgie', '.']
```

Exercice 2

Comparer la tokenisation avec :

- `.split()`
- Spacy

Créer une fonction de tokenisation du texte qui permet à l'utilisateur de choisir la méthode qu'il souhaite :

- Tokenisation par mot
- Tokenisation par caractère
- Tokenisation par subword
- Découpage en phrases

3. Suppression des Mots Vides (Stopwords)

Objectif : Éliminer les mots courants qui n'apportent pas de sens significatif (ex: le, la, de, est).

```
import nltk
from nltk.corpus import stopwords

# Nécessite : nltk.download
# ('stopwords')
stop_words = set(stopwords.words
('french'))
tokens = ['l', 'analyse', 'de',
'sentiments', 'est', 'utile']
filtered_tokens = [w for w in tokens if
not w.lower() in stop_words]
print(filtered_tokens)
# ['analyse', 'sentiments', 'utile']
```

3. Suppression des Stopwords

Stopwords are very common words, such as of, and, the, are rarely of use in information retrieval.

A stop list is a list of such words that are removed during lexical analysis.

e.g.,

"afin", "ah", "ai", "aie", "aient", "aies", "ait", "alors", "après", "as", "attendu", "au", "au-delà", "au-devant", "aucun", "aucune", "audit", "auprès", "auquel", "aura", "aurai", "auraient", "aurais", "aurait", "auras", "aurez", "auriez", "aurions", "aurons", "auront", "aussi", "autour", "autre"

- A long stop list saves space in indexes, speeds processing, and eliminates many false hits.
- However, common words are sometimes significant in information retrieval, which is an argument for a short stop list.
- Long stop words list may lower recall.

3. Suppression des Stopwords

Exemple

*Text = ['Le 07/08: chute dans les escaliers en lien avec une maladresse. Traumatisme crânien au niveau du vertex, **sans** perte de connaissance.']*

nltk_text = ['07/08: chute escaliers maladresse. Traumatisme crânien niveau vertex, perte connaissance.']

spacy_text = ['07/08: chute escaliers lien maladresse. Traumatisme crânien niveau vertex, perte connaissance.']



DEMO

```
import nltk
nltk.download('stopwords')
from nltk.corpus import stopwords
from nltk.tokenize import word_tokenize
```

```
[nltk_data] Downloading package stopwords to
[nltk_data] C:\Users\naima\AppData\Roaming\nltk_data...
[nltk_data] Package stopwords is already up-to-date!
```

```
# French stop words
stop_words = set(stopwords.words('french'))
```

```
# Text to be processed
text = """
Cher confrère, madame a été admise pour une hémorragie cérébrale.
Elle est actuellement aux soins intensifs, et a besoin d'une opération en urgence.
Ce courrier est à transmettre au chef du service Neurochirurgie.
"""
```

```
# Tokenize the text
words = word_tokenize(text)
```

```
# Filter out stop words
filtered_words = [word for word in words if word.casefold() not in stop_words]
```

```
# Join the filtered words back into a string
filtered_text = ' '.join(filtered_words)
```

```
# Print the filtered text
print(filtered_text)
```

Cher confrère , madame a admise hémorragie cérébrale . actuellement soins intensifs , a besoin d'une opération urgente . courrier transmettre chef service Neurochirurgie .

Exercice 3

Modifier la fonction de normalisation en ajoutant l'étape de suppression des mots blancs

- Enlever les mots blancs Anglais
- Enlever les mots blancs Français

4. Racinisation (Stemming) et Lemmatisation

Objectif : Réduire les mots à leur racine ou forme de base pour regrouper les variantes.

- **Stemming** : Coupe les suffixes (ex: 'aimer', 'aimé' -> 'aim'). Rapide mais moins précis.
- **Lemmatisation** : Utilise un dictionnaire pour trouver la forme canonique (ex: 'suis', 'es', 'est' -> 'être'). Plus lent mais plus précis.

```
Stemming (NLTK PorterStemmer - anglais)
from nltk.stem import PorterStemmer
stemmer = PorterStemmer()
print(stemmer.stem("running")) # run
print(stemmer.stem("ran")) # ran
```

```
Lemmatisation (NLTK WordNetLemmatizer - anglais)
from nltk.stem import WordNetLemmatizer
# Nécessite : nltk.download('wordnet')
lemmatizer = WordNetLemmatizer()
print(lemmatizer.lemmatize("running", pos='v')) # run
print(lemmatizer.lemmatize("ran", pos='v')) # run
```

Stemming

Stemming means reducing terms to their “roots” before indexing.

- **e.g.**, *automate(s), automatic, automation* → *automat*
- Helps recall for some queries but harm precision on others.
- Fine distinctions may be lost through stemming.
- Performance of various algorithms is similar.

Lemmatization

Lemmatizing means reducing inflectional/variant forms of a word to its base form.

- e.g.,

Dans les formes peu sévères, ce traitement n'est habituellement pas prescrit

→ *Dans le forme peu sévère, ce traitement ne être habituellement pas prescrire*

DEMO

```
import nltk
nltk.download('punkt')
nltk.download('omw-1.4')
nltk.download('averaged_perceptron_tagger')
nltk.download('wordnet')
```

```
from nltk.stem import SnowballStemmer, WordNetLemmatizer
from nltk.tokenize import word_tokenize
```

```
# English stemmer and Lemmatizer
stemmer = SnowballStemmer('english')
lemmatizer = WordNetLemmatizer()
```

```
# Text to be processed
text = """
Dear colleague,
Madam was admitted for a cerebral hemorrhage.
She is currently in intensive care and needs an emergency operation.
This letter is to be transmitted to the head of the Neurosurgery department.
"""
```

```
# Tokenize the text
words = word_tokenize(text)
```

```
# Perform stemming and Lemmatization on the words
stemmed_words = [stemmer.stem(word) for word in words]
lemmatized_words = [lemmatizer.lemmatize(word, pos='v') for word in words]
```

```
print("Lemmatized words: ", lemmatized_words)
```

```
Lemmatized words: ['Dear', 'colleague', ',', 'Madam', 'be', 'admit', 'for', 'a', 'cerebral', 'hemorrhage', '.', 'S
he', 'be', 'currently', 'in', 'intensive', 'care', 'and', 'need', 'an', 'emergency', 'operation', '.', 'This', 'let
ter', 'be', 'to', 'be', 'transmit', 'to', 'the', 'head', 'of', 'the', 'Neurosurgery', 'department', '.']
```

Exercice 4


Créer une fonction de stemming et lemmatisation qui permet à l'utilisateur de choisir une des méthodes, ou les deux méthodes au même temps

- Stemming
- Lemmatisation



Etapes de prétraitement avancées

Etapes de prétraitement avancées



Projet : IMDB Dataset of 50K Movie Reviews

Prétraitement des données

Nettoyage des données textuelles :

- Transformation en minuscule
- Tokenisation
- Découpage en phrases
- Gestion des mots blancs
- Gestion des caractères spéciaux
- Lemmatisation

Étapes d'Analyse des Données Textuelles

1. Analyse Exploratoire des Données (EDA)

Objectif : Explorer, Générer des Insights, Révéler des Motifs.

 **Analyses statistiques :** Fréquence des mots, Longueur des phrases, N-grams.

 **Visualisation :** Nuages de mots (Word Clouds), Graphiques à barres des termes fréquents, Histogrammes de longueur.

 **Modélisation :** Modélisation de sujets (Topic Modeling).

2. Analyse de Sentiments

Objectif : Prédire le Sentiment d'un Texte.

 **Catégorisation :** Identifier des émotions spécifiques (ex: Joie, Colère, Tristesse).


 **Polarité :** Classer le texte comme Positif, Négatif ou Neutre.

 **Échelle (Scaling) :** Attribuer une note numérique sur une échelle définie (ex: -10 à +10).

Données textuelles : Exploratory Data Analysis

Exploratory Analysis:

- ❑ Exploring data
 - ❑ Generating insights
 - ❑ Testing hypotheses
 - ❑ Revealing underlying hidden patterns in the data.
-
- Word frequency analysis
 - Sentence length analysis
 - Average word length analysis
 - Frequency of different words or phrases






Exploratory Data Analysis

Visualization:

Understand the patterns and trends in the data

- Word clouds
- Bar plots of the most common words
- Histograms of text length
- Bar plots of most common n-grams
- Topic Modeling



Projet : Analyse des données

Analyse des données textuelles

- Sentiment le plus prévalent
- Nombre moyen de mots par commentaire
- Les mots les plus fréquents
- Visualiser les Word clouds
- Bar plots des mots les plus communs
- Histogrammes de la longueur des commentaires

Méthodes d'Embeddings

- Conversion de texte en vecteurs numériques.
- Objectif : Capturer le sens sémantique pour les modèles d'apprentissage.
- Avant le Deep Learning, des méthodes plus simples étaient utilisées.

Bag-of-Words (BoW)

Représente le texte par la fréquence des mots d'un vocabulaire fixe.

Pros:

Simple

Facile à comprendre

Cons:

Ignore l'ordre des mots

Haute dimensionnalité (vecteurs creux)

Pas de sens sémantique

```
from sklearn.feature_extraction.text import CountVectorizer
corpus = ['This is the first document.', 'This document is the second document.']
vectorizer = CountVectorizer()
X = vectorizer.fit_transform(corpus)
print(vectorizer.get_feature_names_out())
print(X.toarray())
```

TF-IDF

Pondère les mots selon leur fréquence dans un document et leur rareté dans le corpus.

Pros:

Réduit l'impact des mots courants
Met en avant les mots importants

Cons:

Ignore toujours l'ordre des mots
Haute dimensionnalité
Sémantique limitée

```
from sklearn.feature_extraction.text import TfidfVectorizer
corpus = ['This is the first document.', 'This document is the second document.']
vectorizer = TfidfVectorizer()
X = vectorizer.fit_transform(corpus)
print(vectorizer.get_feature_names_out())
print(X.toarray())
```

Word Embeddings (ex: Word2Vec)

Apprend des représentations vectorielles denses où les mots similaires ont des vecteurs proches.

Pros:

Capture les relations sémantiques
Basse dimensionnalité (vecteurs denses)

Cons:

Nécessite beaucoup de données
Statique (un vecteur par mot, hors contexte)
Coûteux en calcul

```
from gensim.models import Word2Vec
sentences = [['this', 'is', 'the', 'first', 'sentence'], ['this', 'is', 'the', 'second', 'sentence']]
model = Word2Vec(sentences, min_count=1)
print(model.wv['sentence'])
print(model.wv.most_similar('sentence'))
```

Projet : IMDB Dataset of 50K Movie Reviews

Prétraitement des données

Word Embeddings

- Utiliser TF-IDF ou Word2Vec pour vectoriser les avis



Sentiment Analysis

Sentiment Analysis

Goal: Predict the sentiment of a body of text




Polarity

Positive
Negative
Neutral



Categorization (Emotions)

Angry
Pleased
Confused
Happy




Scaling


-10 +10

- Popular use case in NLP
- Multiple pretrained model checkpoints available for use
- Predefined Hugging Face pipeline task

Sentiment Analysis: what models to use?



Sentiment Analysis: What tools to use?



Projet : IMDB Dataset of 50K Movie Reviews

Prétraitement des données

Analyse des sentiments

- Entraîner un modèle supervisé pour classifier les sentiments (SVM, Arbre de décision)
- Entraîner un modèle non supervisé : TextBlob, Vader
- Evaluer les modèles
- Analyser et comparer les résultats :
 - Sentiment le plus prévalent par méthode
 - Accuracy des méthodes supervisées