

Nom : _____ Ecole : _____
Prénom : _____ Module : _____
Classe : _____ Durée : _____

CONSIGNES générales :

.....

Cours autorisé : oui

Recherches internet autorisées : Oui

Pour une utilisation internet autorisée : Attention : Si les sources ne sont pas indiquées dans vos travaux et si suspicion de plagiat, la copie ne sera pas acceptée et la note de FX sera attribuée.

IA Générative autorisée : non

Exercice : Analyse sémantique des critiques de films IMDb

❖ **Objectifs :**

- Appliquer les concepts fondamentaux du NLP (segmentation, lemmatisation, analyse syntaxique)
- Manipuler des données textuelles à l'aide de bibliothèques comme SpaCy et NLTK
- Comprendre et utiliser des techniques de représentation vectorielle des mots (Word2Vec)
- Construire un modèle de classification de sentiment simple

❖ **Consignes :**

1. Chargez et nettoyez le jeu de données de critiques de films IMDb disponible à l'adresse suivante (2 points):
<https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>
2. Appliquez les techniques de NLP de base sur un échantillon de 500 critiques (5 points):
 - a. Segmentez les critiques en phrases et en mots à l'aide de SpaCy.
 - b. Effectuez la lemmatisation des mots pour obtenir leur forme de base.
 - c. Analysez la structure syntaxique des critiques (parties du discours, relations de dépendance, etc.).
 - d. Commentez les observations et les insights obtenus sur la structure et le style d'écriture des critiques.
3. Explorez les caractéristiques lexicales des critiques en utilisant des représentations vectorielles des mots (5 points):
 - a. Entraînez un modèle Word2Vec sur l'ensemble du jeu de données.
 - b. Visualisez et analysez les vecteurs de mots obtenus. Identifiez des relations sémantiques intéressantes.
 - c. Utilisez les vecteurs de mots pour calculer la similarité entre critiques. Commentez les résultats.
4. Construisez un modèle de classification simple pour prédire le sentiment (positif/négatif) des critiques (6 points):
 - a. Préparez les données d'entraînement et de test en associant une étiquette de sentiment à chaque critique.
 - b. Entraînez un modèle de classification (par exemple, une régression logistique) en utilisant les vecteurs de mots comme features.
 - c. Évaluez les performances du modèle (précision, rappel, F1-score) sur les données de test.
 - d. Analysez les erreurs du modèle et discutez des pistes d'amélioration.

5. Présentez succinctement vos démarches, analyses et conclusions. N'hésitez pas à inclure des explications détaillées des visualisations obtenus (2 points).